

Od modeli YOLO do agregacji predykcji

Hackology 2026 · Team 08 · YOLOv11l + WBF ensemble · 369 klas · +130% vs baseline

0.7420

najlepszy uzyskany wynik mAP@0.5

YOLO variants


fine-tuning

pseudo-labeling

ensemble

1. Punkt startowy: szybki pipeline

Najpierw sprawdziliśmy, które warianty YOLO i ustawienia dają sensowny kierunek.



Wniosek z etapu pojedynczych modeli

- Pierwszy krok: naiwny fine-tuning YOLO11l na oryginalnych danych (imgsz=640, domyślne hiperparametry) — wynik mAP@0.5 = 0.3221 i pierwsze miejsce na początku konkursu.
- Odkrycie: sweep imgsz inferencji bez retreningu — model trenowany na 640px daje mAP 0.83 przy 960px vs 0.80 przy 640px. Reguła: $\text{imgsz_opt} \approx 1.5 \times \text{imgsz_treningowy}$.
- Postęp iteracyjny: augmentacje (mosaic, mixup) -> 0.65; pseudo-labeling x2 rundy na zbiorze testowym -> 0.72; WBF z 5 źródeł -> 0.7420 (final tag).

2. Co finalnie trafiło do agregacji?

Z logów: 4 unikalne pliki wag oraz 5 źródeł predykcji w ensemble.


Model / wagi	Architektura	Trening	Użycie w ensemble
best_opus_pseudo_ft.pt	YOLO11L, 25.6M	pseudo-label r2, imgsiz 768, AdamW	960 w=2.0 + 768 w=1.0
pseudo_r2_20260524.pt	YOLO11L, 25.6M	imgsiz 1280, lr 0.0001	960 w=2.0
best_pseudo_refit_v1.pt	YOLO11L, 25.6M	pseudo-labeling, AdamW	1280 w=0.5
best_yolo11m_dpr_ft.pt	YOLO11M, 20.3M	DPR fine-tune, batch 16	1280 w=0.5

Idea: zamiast ufać jednemu modelowi, łączymy kilka modeli trenowanych na różnych wariantach danych i uruchamianych z różną rozdzielczością. WBF (iou_thr=0.7) uśrednia pozycje boxów zamiast wybierać jeden.

3. Dlaczego uważaliśmy, że agregacja zadziała?

Mieliśmy konkretne powody techniczne — nie zgadywaliśmy.

Schemat



Ważone predykcje:

większa waga = większe zaufanie do źródła

Różne rozdzielczości

960 i 1280 px pomagają inaczej łapać małe oraz większe obiekty na tej samej płócie.

Różne treningi

pseudo-labeling i fine-tuning zmieniają rozkład błędów — inne FP, inne FN.

Ważenie modeli

mocniejsze źródła (val 0.83) dostają wagę 2x, słabsze (val 0.74) — wagę 0.5.

Mniej przypadkowości

pojedynczy false positive ma mniejszą szansę przebić się przez agregację WBF.

4. Najlepszy wynik i interpretacja

Główna metryka: mAP@0.5 (im wyżej, tym lepiej). Final tag = commit 1693fcb.

0.7420

finalny najlepszy wynik Team 08

5

źródeł predykcji w agregacji

4

unikalne pliki wag

Komentarz do rezultatu

- Wynik 0.7420 oznacza, że finalna agregacja WBF była skuteczniejsza niż traktowanie pojedynczego modelu jako jedynego źródła prawdy (+130% vs naive baseline 0.3221).
- Kluczowy kompromis: 8 źródeł poprawiło val mAP (+1.5pp), ale pogorszyło public (-0.4pp) przez maxDets=100. Wybraliśmy 5 źródeł po analizie tego efektu.
- Koszt ensemble: 8.5 min / 481 obrazów (T4) vs ~2 min single model — 4x wolniej. Mieści się w limicie 30 min; świadomy kompromis: +5pp mAP za dłuższy czas inferencji.
- Gap val->public: 0.8528->0.7420 (ratio 0.87). Przy 8 źródłach val +1.5pp, ale public -0.4pp — maxDets=100 faworyzuje mniej, lecz pewniejsze predykcje.

5. Podsumowanie i wnioski

Od naiwnego baseline do komplementarnego ensemble — co zadziało i dlaczego.

Najkrócej

Zaczęliśmy od szybkiego baseline (0.3221) żeby sprawdzić, że pipeline działa. Finalnie najlepszy efekt dała agregacja WBF kilku modeli YOLO z różnymi ustawieniami, rozdzielczościami i wagami — wynik 0.7420 public mAP@0.5.

Co działo

- fine-tuning YOLO11l
- pseudo-labeling (2 rundy)
- ensemble WBF zamiast single model

Dlaczego

- modele widzą dane inaczej
- różne rozdzielczości inferencji
- redukcja losowych FP przez agregację

Pułapki i limity

- maxDets=100 tnie recall — gęste półki nierozwiązane
- więcej źródeł WBF hurt public przez FP w top-100
- val mAP != public mAP — nie optymalizuj val naiwnie

Finalny przekaz: wynik 0.7420 uzyskano dzięki połączeniu komplementarnych modeli, a nie przez jedną zmianę hiperparametru.

6. Możliwości dalszego rozwoju

Co można poprawić przy więcej czasu lub zasobów obliczeniowych.

SAHI tile inference

Sliding window 1280×1280 px dla gęstych półek (>100 produktów/zdjęcie). Eliminuje hard ceiling maxDets=100 — potencjał +5-10pp dla najtrudniejszych obrazów.

Confidence calibration per-class

Kalibracja progów confidence dla każdej z 369 klas osobno. Zmniejsza FP między wariantami tej samej marki (np. Pepsi 0.33L vs 0.5L).

Hierarchia taksonomii

Grupowanie 369 klas wg brand + typ + pojemność, potem two-stage detect+classify. Precyzyjniejsza klasyfikacja wariantów przy zachowaniu szybkości detekcji.

Więcej danych i pseudo-labeling r3

Dane syntetyczne (SDXL) dla rzadkich klas (<5 próbek). Trzecia runda pseudo-labelingu na zbiorze rozszerzonym o trudne przypadki.