

Team 08

Od modeli YOLO do agregacji predykcji

Minimalne podsumowanie podejścia w zadaniu object detection.

0.7420

najlepszy uzyskany wynik mAP@0.5

YOLO variants


fine-tuning

pseudo-labeling

ensemble

1. Punkt startowy: pojedyncze modele

Najpierw sprawdzaliśmy, które warianty YOLO i ustawienia dają sensowny kierunek.



Wniosek z etapu pojedynczych modeli

- Wynik pojedynczego modelu mocno zależał od rozdzielczości inferencji i jakości fine-tuningu.
- Modele po pseudo-labelingu zaczęły dawać lepsze i bardziej stabilne predykcje.
- Najlepszy pojedynczy model nie był wystarczająco stabilny, dlatego przeszliśmy do agregacji.

2. Co finalnie trafiło do agregacji?

Z logów: 4 unikalne pliki wag oraz 5 źródeł predykcji w ensemble.

Model / wagi	Architektura	Trening	Użycie w ensemble
best_opus_pseudo_ft.pt	YOLO, fine-tune	imgsz 768, AdamW, mosaic 0.7	960 w=2.0 + 768 w=1.0
pseudo_r2_20260524.pt	YOLO11L, 25.6M	imgsz 1280, lr 0.0001	960 w=2.0
best_pseudo_refit_v1.pt	YOLO11L, 25.6M	pseudo-labeling, AdamW	1280 w=0.5
best_yolo11m_dpr_ft.pt	YOLO11M, 20.3M	DPR fine-tune, batch 16	1280 w=0.5

Idea: zamiast ufać jednemu modelowi, łączymy kilka modeli trenowanych na różnych wariantach danych i uruchamianych z różną rozdzielczością.

3. Dlaczego agregacja mogła zadziałać?

Ensemble zwykle poprawia stabilność, bo modele popełniają różne błędy.

Schemat

predykcje modelu A

predykcje modelu B

predykcje modelu C

NMS /
fusion

Ważone predykcje:

większa waga = większe zaufanie

Różne rozdzielczości

960 i 1280 pomagają inaczej łapać małe oraz większe obiekty.

Różne treningi

pseudo-labeling i fine-tuning zmieniają rozkład błędów modeli.

Ważenie modeli

mocniejsze źródła dostają większą wagę, słabsze działają pomocniczo.

Mniej przypadkowości

pojedynczy false positive ma mniejszą szansę przebić się przez agregację.

4. Najlepszy wynik i interpretacja

Główna metryka zadania: mAP@0.5, czyli im wyżej, tym lepiej.

0.7420

finalny najlepszy wynik Team 08

5

źródeł predykcji w agregacji

4

unikalne pliki wag

Komentarz do rezultatu

- Wynik 0.7420 oznacza, że finalna agregacja była skuteczniejsza niż traktowanie pojedynczego modelu jako jedyne źródła prawdy.
- Największy wpływ mogły mieć: pseudo-labeling, mocniejsze warianty YOLO11, wyższe rozdzielczości inferencji oraz dobrane wagi modeli.
- Ryzyko: private set może różnić się od publicznego, dlatego stabilność ensemble jest ważniejsza niż jednorazowy wynik pojedynczego modelu.

5. Co warto powiedzieć w podsumowaniu?

Krótką narracją do prezentacji wyniku.

Najkrócej

Zaczęliśmy od eksperymentów z pojedynczymi modelami YOLO. Finalnie najlepszy efekt dała agregacja kilku wytrenowanych modeli z różnymi ustawieniami, rozdzielczościami oraz wagami w ensemble.

Co działało

- fine-tuning
- pseudo-labeling
- ensemble zamiast single model

Dlaczego

- modele widzą dane inaczej
- różne rozdzielczości
- redukcja losowych błędów

Co zabezpieczyć

- wagi .pt
- konfiguracje treningu
- pipeline predykcji

Finalny przekaz: najlepszy wynik 0.7420 uzyskano dzięki połączeniu komplementarnych modeli, a nie przez jedną zmianę hiperparametru.